

KI-Infrastruktur Spengergasse

Drei Wege – Daten, Preise, Entscheidungen

Georg Graf · 2026-06-24

Kontext

2.600 Schüler · 280 Lehrer · 97 Klassen

Davon $\sim 2/3$ in IT/Design-Abteilungen: ~ 1.700 potenzielle KI-Nutzer.

Davon aktiv (tägliche Nutzung): ~ 680 .

DSGVO als Grundanforderung.

Open-Source-LLMs haben den Abstand zu Closed Source von 17 auf 2–3 Prozentpunkte geschlossen (2023 → 2026).

Open Source hat aufgeholt

Benchmark	Open Source	Closed Source
SWE-bench Pro	GLM-5.2 62.1 (MIT)	GPT-5.5 58.6
SWE-bench Verified	DeepSeek V4 Pro 80.6	Claude Opus 4.8 88.6
LiveCodeBench	DeepSeek V4 Pro 93.5	GPT-5.3 Codex 85.0
Terminal-Bench 2.1	GLM-5.2 81.0	Claude Opus 4.8 85.0
GPQA Diamond	Qwen 3.5 88.4	Claude Opus 4.6 ~85
AIME 2026	GLM-5.2 99.2	–

LiveCodeBench: Open Source führt. Terminal-Bench: 4 Punkte Rückstand. Stand Juni 2026.

Preise & Lizenzen pro Million Tokens

Modell	Eingang	Ausgang	Lizenz
GLM-5.2	\$1.40	\$4.40	MIT
DeepSeek V4 Flash	\$0.14	\$0.28	MIT
DeepSeek V4 Pro	\$0.44	\$0.87	MIT
Qwen 3.6-27B	\$0.10	\$0.15	Apache 2.0
SiliconFlow (günstigste)	\$0.05	–	offen
GPT-5.5	\$5.00	\$30.00	–
Claude Opus 4.8	\$5.00	\$25.00	–

Faktor 35–100x zwischen Open und Closed. Keine Lizenzkosten, keine MAU-Limits. Preise Stand 2026-06-24.

Vendor Lock-In ist real

12. Juni 2026

US-Exportkontrolle sperrt Claude Fable 5 (SWE-bench 95.0 %) für alle Nicht-US-Nutzer. Über Nacht. Kein Ersatz.

OpenAI: 33 Modelle in einem Monat retired (Januar 2025).

Anthropic: Drittanbieter-Agents auf Pro/Max verboten (April 2026).

Preise: GPT-5.5 doppelt so teuer wie GPT-5.4. Keine Ankündigung.

Geschlossene APIs: morgen teurer, morgen weg, morgen anders.

Option A: On-Premise

Management-VM (LiteLLM + Open WebUI + SearXNG) + GPU-Knoten (vLLM)

Hardware	Speicher	Preis
AMD Strix Halo Mini PC	96 GB unified	ab \$1.479
Mac Mini M4 Pro	48 GB unified	\$1.799
Mac Mini M4 Pro	64 GB unified	~\$2.000
AMD Strix Halo Dev Kit	128 GB unified	\$3.999
NVIDIA DGX Spark	128 GB unified	~€4.950
4× Mac Mini Pro (EXO)	192 GB pooled	~\$7.200

Strom: 40–300W pro Gerät. Alle mit vLLM, Ollama oder llama.cpp. Preise Stand 2026-06-24.

Option A: Kosten

Szenario	Jahr 1	Jahr 2	Jahr 3
1 Knoten + Management-VM	~€4.000	~€500	~€500
3 Knoten (erweitert)	~€12.000	~€1.500	~€1.500
Vergleich: ChatGPT Edu (1.700 Sitz)	~€204.000	~€204.000	~€204.000

Break-even nach 2–3 Jahren. Danach nur noch Strom + Wartung.

Option B: GPU mieten

EU-souverän – kein CLOUD Act:

Anbieter	GPU	Preis
Hetzner GEX44	RTX 4000 Ada 20 GB	€184/Monat
Hetzner GEX131	RTX PRO 6000 96 GB	€889/Monat
OVHcloud	H100	~\$3.20/h
Gcore	H100	~\$3.10/h

Neo-Clouds (günstiger, global):

Anbieter	GPU	Preis
Spheron	H100 spot	ab \$1.03/h
Vast.ai	RTX 4090	ab \$0.35/h
Lambda	H100	\$2.49/h

Hyperscaler (AWS, Azure, GCP): H100 ~\$12–14/h. Preise Stand 2026-06-24.

Option C: API-Abos

Realistisches Szenario: 680 aktive Nutzer, 5.000 Tokens/Tag, 190 Schultage

→ **~646 Millionen Tokens/Jahr**

Anbieter	Kosten/MTok	Kosten/Jahr
SiliconFlow (günstigste)	\$0.05	~€30
DeepSeek V4 Flash	\$0.14 / \$0.28	~€270
DeepSeek V4 Pro	\$0.44 / \$0.87	~€400
GLM-5.2 (API)	\$1.40 / \$4.40	~€1.700
ChatGPT Edu (1.700 Sitz)	~\$10/Sitz/Monat	~€170.000

Bei API-Kosten unter €500/Jahr stellt sich die On-Premise-Frage nicht mehr finanziell, sondern datenschutzrechtlich.

Vergleich

Kriterium	On-Premise	GPU mieten	API-Abos
Kosten Jahr 1	€4.000–12.000	~€2.000–7.000	€30–204.000
Kosten Jahr 3	~€500–1.500	~€2.000–7.000	€30–204.000
Datenschutz	vollständig	anbieterabhängig	extern
Modellauswahl	alle Open	alle	API-abhängig
Vendor Lock-In	keiner	gering	hoch
Wartung	selbst	gering	keine

API (Open-Source-Dienste): extrem günstig, aber Daten verlassen das Schulnetz.

Hardware-Trend

Preis pro Token fällt exponentiell. DRAM-Schock 2025/26 ist temporär.

**2023 → 2026: GPU-Preis/Token
um Faktor 5–10 gefallen.**

2027/28 zu erwarten:

- Rubin-Generation drückt H100-Preise
- AMD MI400 + Intel Gaudi 3: mehr Wettbewerb
- DRAM-Kapazitäten hochgefahren
- MoE-Modelle effizienter (GLM-5.2: 5 % aktiv)

| *Wer heute sparsam startet, kauft morgen günstiger ein.*

Ein möglicher Weg

Phase 1 (2026/27):

1 On-Premise-Knoten (Strix Halo / Mac Mini) + Management-VM

- API für Massenlast (DeepSeek V4 Flash, ~€270/Jahr).
~€4.000 einmalig, ~€800/Jahr laufend.

Phase 2 (2027/28):

Hardware nachkaufen, wenn Preise fallen.

API-Anteil sinkt. ~€3.000–5.000 zusätzlich.

Phase 3 (2028+):

~90 % On-Premise. API nur für Spitzenlast.

Modelle von 2028 auf Hardware von 2026.

Die API-Kosten in Phase 1 sind vernachlässigbar. Der Rest ist DSGVO und Souveränität.

Nächste Schritte

- Pilotklasse Q3 2026 – 1 Knoten + API
- Evaluierung nach einem Semester
- Hardware-Entscheidung auf Basis echter Daten
- Open-Source-Modelle evaluieren: GLM-5.2, DeepSeek V4, Qwen 3.6

Danke

Georg Graf · grafg@spengergasse.at

github.com/Die-Spengergasse/Ilm-on-premise